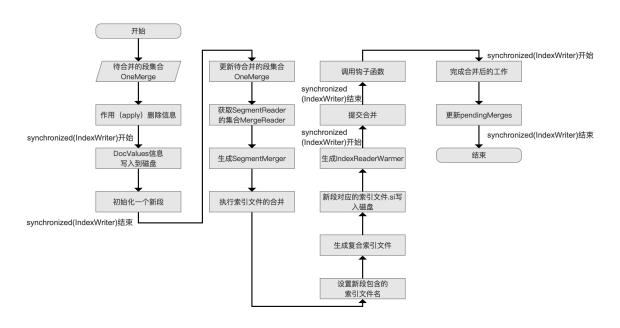
# 执行段的合并 (二)

本文承接<u>执行段的合并(一)</u>,继续介绍执行段的合并的剩余的流程,下面先给出执行段的合并的 流程图:

#### 图1:



#### 点击查看大图

## DocValues信息写入到磁盘

在上一个流程点作用(apply)删除信息执行结束后,待合并的段中新增的删除信息目前还存储在内存中,此时需要持久化DocValues信息,即写入到磁盘。

删除信息可以分为下面两类:

- 被删除的文档号: 这类删除信息使用<u>FixedBitSet</u>存储,按照Term进行删除、按照Query进行删除、更新文档操作这三种操作找出的文档号都是被删除的文档号
- DocValues信息: 这类删除信息使用链表存储,这里不展开介绍,在以后介绍软删除的文章中会展开,更新DocValues域的操作会产生这类删除信息

在源码中,该流程点有以下的TODO注释:

TODO: we could fix merging to pull the merged DV iterator so we don't have to move these updates to disk first, i.e. just carry them in memory:

也就是说没有必要在这个流程将变更的DocValues信息写入到磁盘,由于由于执行段的合并跟<u>文档的增删改</u>,文档提交(<u>commit</u>、<u>flush</u>)是并发的操作,DocValues还有可能被更新,故在以后的版本,将不需要在这个位置执行该流程,而是跟处理被删除的文档号一样,通过OneMerge存储(仅仅是作者的猜测,至少被删除的文档号是这么做的),OneMerge中包含的信息见文章<u>执行段的合并(一)</u>

中的介绍,在后面的流程中会介绍处理被删除的文档号的过程。

至于DocValues信息从内存持久化到磁盘的过程,在以后介绍软删除的文章中会展开,在这篇文章中我们只需要知道,当前流程执行结束后,会生成新的.dvd、.dvm的索引文件。

# 初始化一个新段

新段newSegment即待合并的段合并后的目标段(target segment),在合并操作中初始化一个新段的过程有以下五个步骤:

● 步骤一之获得新段的段名前缀:使用jdk提供的Long.toString(count, Character.MAX\_RADIX)方法来获得,demo看这里:<a href="https://github.com/LuXugang/Lucene-7.5.0/blob/master/LuceneDemo/src/main/java/lucene/index/NewSegmentTest.java">https://github.com/LuXugang/Lucene-7.5.0/blob/master/LuceneDemo/src/main/java/lucene/index/NewSegmentTest.java</a>,下图的例子显示的是连续获取80个段名前缀,可以看出命名方式就是0~9、a~z的组合值:

#### 图2:

#### newSegmentPrefixName: \_1 \_2 \_3 \_4 \_5 \_6 \_7 \_8 \_9 \_a \_b \_c \_d \_e \_f \_g \_h \_i \_j \_k \_l \_m \_n \_o \_p \_q \_r \_s \_t \_u \_v \_w \_x \_y \_z \_10 \_11 \_12 \_13 \_14 \_15 \_1 \_17 \_18 \_19 \_1a \_1b \_1c \_1d \_1e \_1f \_1g \_1h \_1i \_1j \_1k \_1l \_1m \_1n \_1o \_1p \_1q \_1r \_1s \_1t \_1u \_1v \_1v \_1x \_1y \_1z \_20 \_21 \_22 \_23 \_24 \_25 \_26 \_27 \_28

- 步骤二之生成SegmentInfo对象:在当前阶段SegmentInfo对象中的变量都是初始化的数据,在后面的流程中会不断的更新SegmentInfo对象中的信息
  - SegmentInfo对象是什么:
    - <u>索引文件si</u>中包含的索引信息读取到内存后就用SegmentInfo对象来描述,反之生成<u>索引文件si</u>的过程就是将SegmentInfo对象中的信息持久化到磁盘,所以SegmentInfo对象中的信息如图3所示
- 步骤三之初始化SegmentInfo对象中的Diagnostics: 如果是通过flush生成一个新的SegmentInfo 对象,那么会将以下的信息初始化Diagnostics:
  - 。 初始化的Diagnostics包含的字段:
    - os: 运行Lucene所在的操作系统,版本号,架构,比如操作系统为Mac OS X,版本号为10.14.3,架构为x86\_64
    - java: java的发行商, 版本号, JVM的版本号
    - version: Lucene的版本号, 比如7.5.0
    - source: 生成当前segment是由什么触发的, flush、commit、merge、addIndexes(facet)
    - timestamp: 生成当前segment的时间戳
  - o 由于是通过merge生成的SegmentInfo对象,所以会额外多两个字段:
    - mergeMaxNumSegments: 该字段在forceMerge中会用到,这里不开展解释
    - mergeFactor:新段是由mergeFactor个旧段合并生成的
  - o Diagnostics在索引文件si中的位置如下图所示,红框标注:

#### 图3:



- 步骤四之生成SegmentCommitInfo对象:根据SegmentInfo对象生成一个SegmentCommitInfo 对象,该对象不展开介绍,已经解释过好多次了,同样的,在这个阶段,SegmentCommitInfo对 象中的变量都是初始化,在后面的流程中会更新
- 步骤五之更新OneMerge:在<u>执行段的合并(一)</u>中我们介绍到,OneMerge在后面的流程中,它 包含的变量会逐步更新,在这里OneMerge中的SegmentCommitInfo会被更新,即新段的信息被 更新到OneMerge中

## 更新待合并的段集合OneMerge

在介绍该流程之前,我们先讲述下Lucene中两个很重要的类ReadersAndUpdates、ReaderPool。

## ReadersAndUpdates

ReadersAndUpdates用来维护一个段的信息,比如删除信息的更新,段的复用(<u>NRT近实时搜</u> <u>索</u>)等,查询、合并操作都会用到ReadersAndUpdates,它包含的几个重要的变量如下所示:

- SegmentCommitInfo info: 该字段描述了一个段的完整索引信息(除了删除信息),见近实时搜索NRT(四)
- SegmentReader reader: 当需要读取段的索引信息时,我们可以复用该对象,降低读取开销(复用、提高读取性能的概念见文章SegmentReader (一)
- PendingDeletes pendingDeletes: 上文中我们说到删除信息被分为两类,被删除的文档号和 DocValues信息, PendingDeletes对象中包含了一个<u>FixedBitSet</u>对象来存储被删除的文档号
- boolean isMerging: 该字段用来描述当前段是否正在执行合并操作
- Map<String,List<DocValuesFieldUpdates>> pendingDVUpdates: 如果当前段中的DocValues信息需要更新,那么DocValues信息用该Map容器存放
- Map<String,List<DocValuesFieldUpdates>> mergingDVUpdates: 如果当前段中的DocValues信息需要更新,但是当前段正在更新,那么DocValues信息会先用pendingDVUpdates存放,同时用该Map容器存放

## ReaderPool

ReaderPool中包含了一个容器,其定义如下:

```
private final Map<SegmentCommitInfo,ReadersAndUpdates> readerMap = new
HashMap<>();
```

ReaderPool是IndexWriter的变量,所以ReaderPool的作用是在持有IndexWriter的情况下能通过 SegmentCommitInfo找到每一个段的ReadersAndUpdates,故IndexWriter、ReaderPool、 ReadersAndUpdates三者的关系如下:

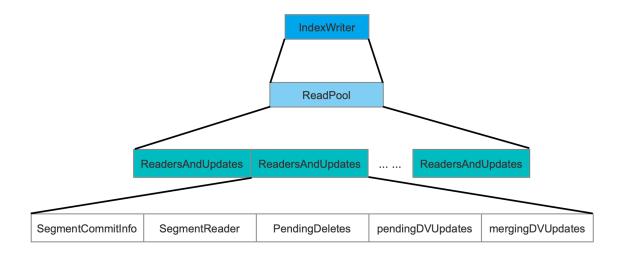


图4中ReadersAndUpdates的个数即当前索引目录中段的个数。

#### ReadersAndUpdates在什么时候生成:

 作用删除信息:如果当前段需要被作用删除信息,如上文描述的,删除信息会被存储到当前段的 ReadersAndUpdates或pendingDVUpdates或mergingDVUpdates中,故如果ReaderPool中没有 该段的ReadersAndUpdates,那么就会生成ReadersAndUpdates,生成的时间点在下面的流程图 中红框标注:

图5:

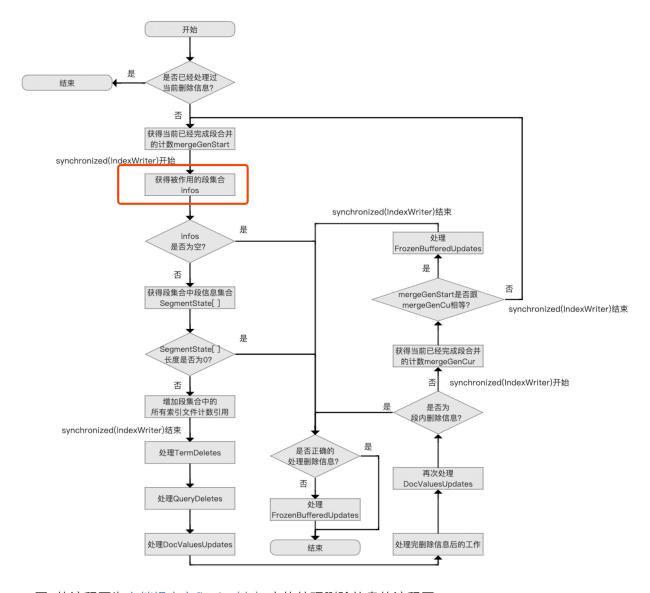


图5的流程图为文档提交之flush(七)中的处理删除信息的流程图。

 合并阶段:合并期间需要合并删除信息,故同样使用ReadersAndUpdates来获得每一个待合并的 段删除信息,如果某个段在ReadPool中没有ReadersAndUpdates对象,那么先生成该 ReadersAndUpdates对象

我们回到流程点更新待合并的段集合OneMerge,在当前流程点我们需要更新OneMerge中的两个变量,如下所示,OneMerge中包含的信息见文章<u>执行段的合并(一)</u>中的介绍:

- List<SegmentReader> readers: readers中的每一个SegmentReader描述的是某个待合并的段的信息,并且SegmentReader是通过ReadersAndUpdates获得的
- List<Bits> hardLiveDocs: hardLiveDocs中的每一个Bits描述的是某个待合并的段中被标记为删除的文档号集合,并且hardLiveDocs是通过SegmentReader获得的

# 获取SegmentReader的集合MergeReader

该流程会涉及软删除的概念,基于篇幅,将在下一篇文章中展开。

# 结语