两阶段生成索引文件之第一阶段

在前面的文章中,介绍了大部分的<u>索引文件</u>的数据结构,而从这篇文章开始,用两篇文章的篇幅来 介绍例如索引文件是如何生成的,索引文件之间生成的先后顺序等内容。 索引文件两个阶段生成:

- 第一阶段:添加文档阶段,也就是IndexWriter调用addDocument(..)或updateDocument(...),在此阶段会生成<u>.fdx</u>、<u>.tvd</u>、<u>.tvd</u>、<u>tvx</u>索引文件
- 第二阶段: flush或commit阶段,在此阶段会生成<u>.liv</u>、<u>.dim、.dii</u>、<u>tim、.tip</u>、<u>.doc</u>、<u>pos、.pay</u>、<u>nvd、.nvm</u>、<u>.dvm、,dvd</u>索引文件。

本篇文章介绍第一阶段,建议大家可以先看下索引文件的索引结构,因为在下文的介绍中,会根据 随着流程进度介绍对应索引文件的数据结构。

预备知识

term

term指的是对域值分词后的token,例如下图中域名为"content"的域(Field),它的域值为"it is good":

图1:

```
doc.add(new Field( name: "content", value: "it is good", type));
```

在使用空格分词器后, 我们就可以得到3个term: "it"、"is"、"good"。

IndexOptions

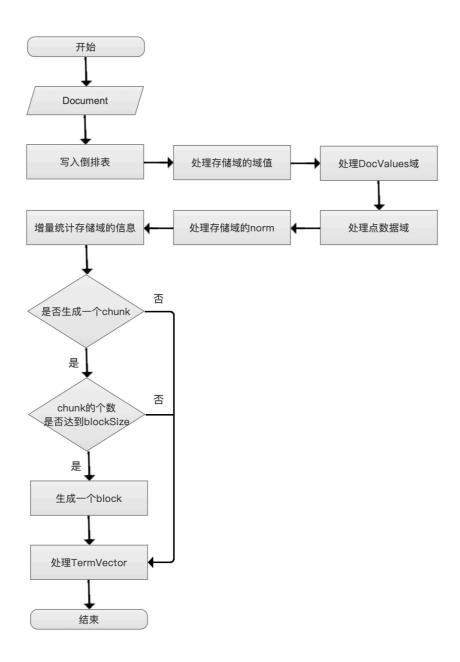
索引选项(IndexOptions),如果你希望定义的域在搜索阶段能根据该域进行搜索,那么必须至少设置一个非NONE的索引选项,这样才能将这个域的写入到倒排表中,并最后写入到索引文件,索引选项有以下几种:

- NONE: 该域的信息不会写入到倒排表中, 那么在索引阶段无法通过该域名进行搜索
- DOCS: 只有域所属的文档(Document)号被写入到倒排表中,在搜索阶段,PhraseQuery,或者需要位置信息的Query会抛出异常,由于不记录term(分词后的域值)的位置词频信息,所以对文档打分时,即使该term在一篇文档中出现多次,也会被当成只出现一次进行处理。
- DOCS_AND_FREQS: 只有域所属的文档号和term的词频(frequency)被写入到倒排表中,但是由于没有记录term在文档中的位置信息,所以同样的在搜索阶段,PhraseQuery,或者需要位置信息的Query会抛出异常
- DOCS_AND_FREQS_AND_POSITIONS: 只有域所属的文档号和term的词频(frequency)及位置(position)被写入到倒排表中,该选项是需要进行全文搜索的域的默认的索引选项
- DOCS_AND_FREQS_AND_POSITIONS_AND_OFFSETS: 域所属的文档号和term的词频(frequency)及位置(position)及偏移(offset)被写入到倒排表中

文档号、词频、位置、偏移的概念在倒排表(上)中有详细介绍。

流程图

图2:



Document

图3:

Document

Document即我们定义的Document对象,一个Document对象中可以有多种域,下图中一个Document中包含了域名为"content"的存储域、域名为"space"的点数据域、域名为"author"的DocValues域。

图4:

```
FieldType type = new FieldType();
type.setStored(true);
type.setStoreTermVectorS(true);
type.setStoreTermVectorPositions(true);
type.setStoreTermVectorPayloads(true);
type.setStoreTermVectorOffsets(true);
type.setTokenized(true);
type.setIndexOptions(IndexOptions.DOCS_AND_FREQS_AND_POSITIONS_AND_OFFSETS);

Document doc = new Document();
doc.add(new Field( name: "content", getRandomValue(), type));
doc.add(new IntPoint( name: "space", ...point: 3, 4, 6));
doc.add(new SortedDocValuesField( name: "author", new BytesRef(getRandomValue())));
indexWriter.addDocument(doc);
```

写入倒排表

图5:

写入倒排表

只有IndexOptions不为NONE的域才会被写入到倒排表中,在搜索阶段,这样的域才能作为Query的条件进行搜索,下图是一个最基本的根据域进行查询的Query:

图6:

```
Query query = new TermQuery(new Term((fld: "content", (text: "good"));
```

上图中,我们的查询条件是 满足条件的文档必须包含一个叫"good"的term,并且该term是域名为"content"的域值中的完整值或部分值。 写入倒排表的过程在前面的文章中已经介绍,不赘述。

图7:

处理存储域的域值

在当前流程中,需要将域的域值跟域值类型写入到一个bufferedDocs[]数组(在源码中bufferedDocs其实是一个对象,它用来将数据写入到buffer[]中,为了方便介绍,所以我们直接认为bufferedDocs是一个数组)中,目前Lucene7.5.0支持的存储域的域值类型fieldType为下面几种:

● STRING: 固定值: 0x00, 域值为String类型

● BYTE_ARR: 固定值: 0x01, 域值为字节类型

● NUMERIC_INT: 固定值: 0x02, 域值为int类型

● NUMERIC_FLOAT: 固定值: 0x03, 域值为float类型

● NUMERIC_LONG: 固定值: 0x04, 域值为longt类型

● NUMERIC_DOUBLE: 固定值: 0x05, 域值为double类型

bufferedDocs[]数组数据结构如下:

图8:

FieldNumAndType	Value
-----------------	-------

FieldNumAndType

FieldNumAndType是域的编号fieldNum跟域值类型FieldType的组合值, 域的编号是一个从开0开始的递增值,根据域名来获得一个域的编号,FieldNumAndType = fieldNum << 3 | FieldType。比如有以下的一个Document:

Value

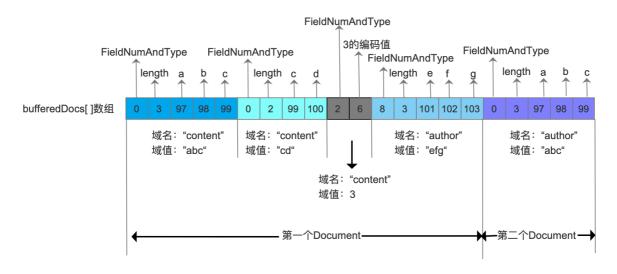
Value即域值,如果是数值类型,那么通过zigZag编码后存储,如果不是,那么按字节存储存储域值,并存储一个length来表示字节的个数。

图9:

```
// 0
doc = new Document();
doc.add(new Field( name: "content", value: "abc", type));
doc.add(new Field( name: "content", value: "cd", type));
doc.add(new StoredField( name: "content", value: 3));
doc.add(new Field( name: "author", value: "efg", type));
indexWriter.addDocument(doc);
// 1
doc = new Document();
doc.add(new Field( name: "content", value: "abc", type));
indexWriter.addDocument(doc);
```

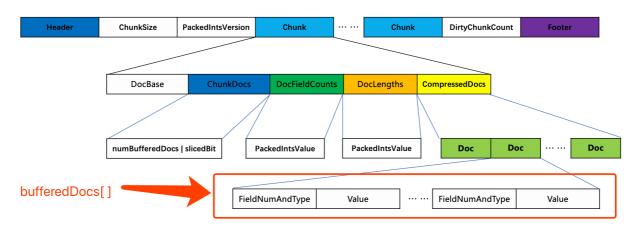
上图中两个Document,共5个存储域,假设当前域"content"的编号是0,域"author"的编号是1,并且根据域值类型,他们的FieldType分别是(0x00)、(0x00)、(0x00)、(0x00)、(0x00)、(0x00)、(0x00)、0x00)、(0x00))、(0

图10:



存储域的域值的信息对应在<u>.fdx、.fdt</u>索引文件中的位置如下图,强调的是下图只是其中一种情况的.fxt的索引文件,详情请看<u>.fdx、.fdt</u>的介绍:

图11:



处理DocValues域

图12:

处理DocValues域

在生成索引文件的第一阶段,负责收集一些数据,根据这些数据在生成索引文件的第二阶段生成.<u>dvm、,dvd</u>索引文件,在下一篇文章中,会详细介绍在第一阶段收集了哪些数据。

处理点数据域

图13:

处理点数据域

在生成索引文件的第一阶段,负责收集一些数据,根据这些数据在生成索引文件的第二阶段生成.<u>dim、.dii</u>索引文件,在两阶段生成索引文件之第二阶段的文章中,会详细介绍在第一阶段收集了哪些数据。

处理存储域的norm

处理存储域的norm

在生成索引文件的第一阶段,负责收集一些数据,根据这些数据在生成索引文件的第二阶段生成 nvd、.nvm 索引文件,在两阶段生成索引文件之第二阶段的文章中,会详细介绍在第一阶段收集了哪些数据。

增量统计存储域的信息

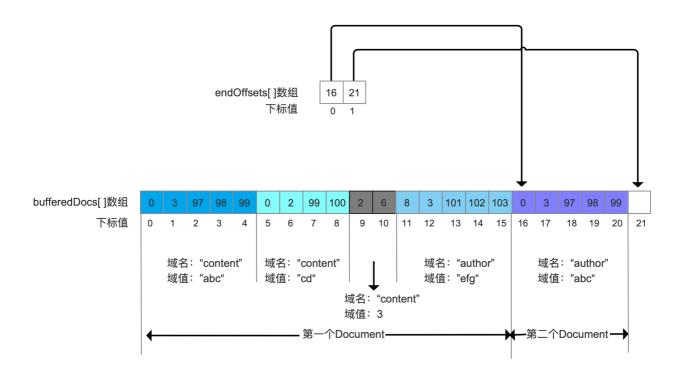
图15:

增量统计存储域的信息

在这个流程点,需要增量的记录下面的数据:

- **numBufferedDocs**:该值是一个从0开始递增的值,每次处理一个Document,该值+1,它描述了一个Document的内部文档号,同时该值也描述了当前生成一个chunk(如果你没看过.fdx、.fdt,下文会介绍)前已经处理的文档数量
- **numStoredFields[]数组**:该数组的下标值是numBufferedDocs,数组元素是numBufferedDocs对应的Document中包含的存储域的个数
- **endOffsets[]数组**: 该数组的下标值是numBufferedDocs,数组元素是一个索引值,该值作为bufferedDocs[]数组的下标值,用来得到numBufferedDocs对应的Document中所有存储域的域值在bufferedDocs[]数组中的偏移位置

图16:



是否生成一个chunk

图17:



IndexWriter每次添加完一篇文档,就会判断两个条件,如果满足其中任意一个,那么需要生成一个chunk。

- 条件1:是否已经添加了maxDocsPerChunk篇文档
- 条件2: 是否存储域的域值的大小是否超过chunkSize(字节)

通过numBufferedDocs来判断是否满足条件1,通过bufferedDocs[]数组来判断是否满足条件2。chunkSize的值根据存储域的配置选项(Configuration option for stored fields)有两种值:

● BEST_SPEED:该模式下maxDocsPerChunk的值为128, chunkSize的值为1 << 14, 即16384, 这种模式有较快的检索索引速度,较低的压缩率,即生成的索引文件较大,是一种压缩率换检索速度的方式(Trade compression ratio for retrieval speed)

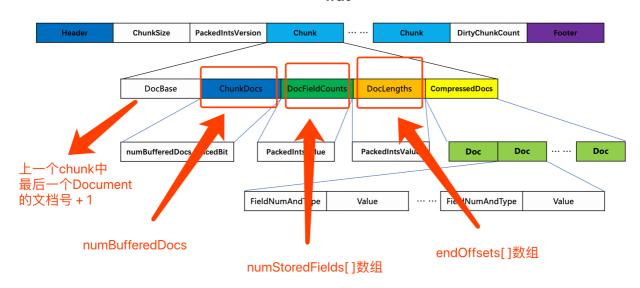
● BEST_COMPRESSION:该模式下maxDocsPerChunk的值为512,chunkSize的值为61440,这种模式有较高的压缩率,即生成的索引文件较小,但较慢的索引速度,是一种检索速度换压缩率的方式(Trade retrieval speed for compression ratio)

在创建IndexWriter对象时,用户可以通过IndexWriterConfig来自行选择一种模式,默认是BEST SPEED模式。

存储域的一个chunk信息对应在.fdx、.fdt索引文件中的位置如下图:

图18:





这里需要强调的是,endOffsets[]中记录的是每个Document的域值在bufferedDocs[]数组中的偏移位置,也就是告诉我们每个Document的存储域的域值长度,另外DocBase的值是上一个chunk中最后一篇文档的文档号加1。

另外每生成一个chunk,我们需要记录跟chunk相关的信息,在后面的流程需要用到这些信息来生成索引文件,即.fdx文件。

- **startPointerDeltas[]数组**:该数组的下标值是一个从0开始的递增值,它用来代表一个chunk,数组元素是该chunk在.fdt文件中的偏移位置,偏移位置使用差值存储
- **docBaseDeltas[]数组**:该数组的下标值是一个从0开始的递增值,同样地代表一个chunk,数组元素是该chunk中包含的文档个数,文档个数使用差值存储

chunk的个数是否达到blockSize

图19:



当chunk的个数达到blockSize,那么需要在索引文件.fdx中生成一个block,用该block来描述这blockSize个chunk在.fdt中的位置。

blockSize在Lucene7.5.0版本中是固定值1024,跟BEST_SPEED还是BEST_COMPRESSION模式无关。

生成一个block

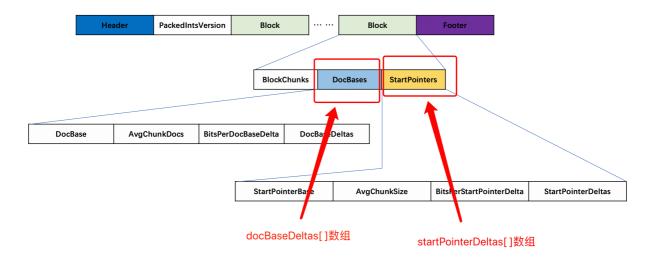
图20:

生成一个block

当chunk的个数达到1024个,那么把这1024个chunk在.fdx中的偏移位置及包含的文档数生成一个block,写到.fdx文件中。

图21:

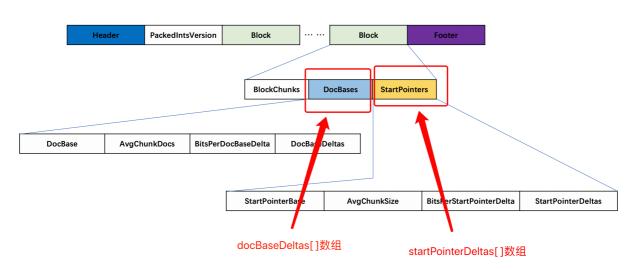
.fdx



处理TermVector

图21:

.fdx



大家通过看TermVector的<u>.tvd、tvx</u>索引文件会发现其索引结构跟存储域的索引文件及其相似,故 其逻辑是类似的,所以就不赘述了。

结语

没啥好说的。

点击下载Markdown文件