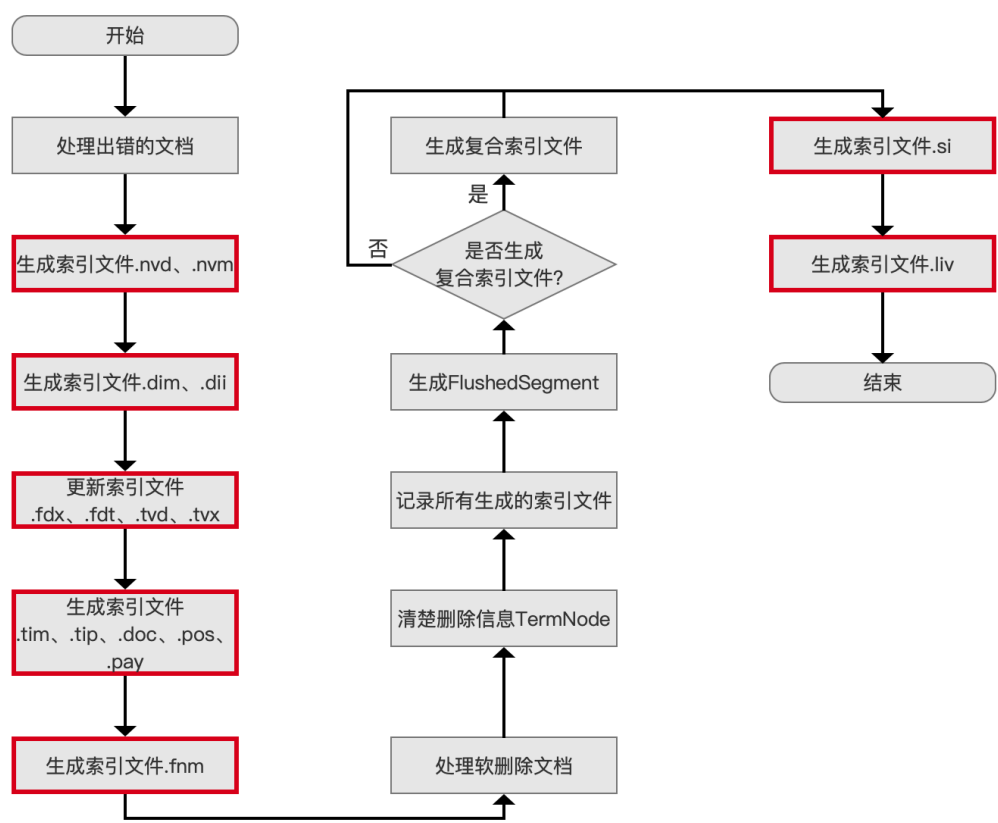


# 索引文件的生成 (一)

在执行flush()的过程中，Lucene会将内存中的索引信息生成索引文件，其生成的时机点如下图红色框标注：

图1：

将DWPT中收集的索引信息生成一个段newSegment的流程图



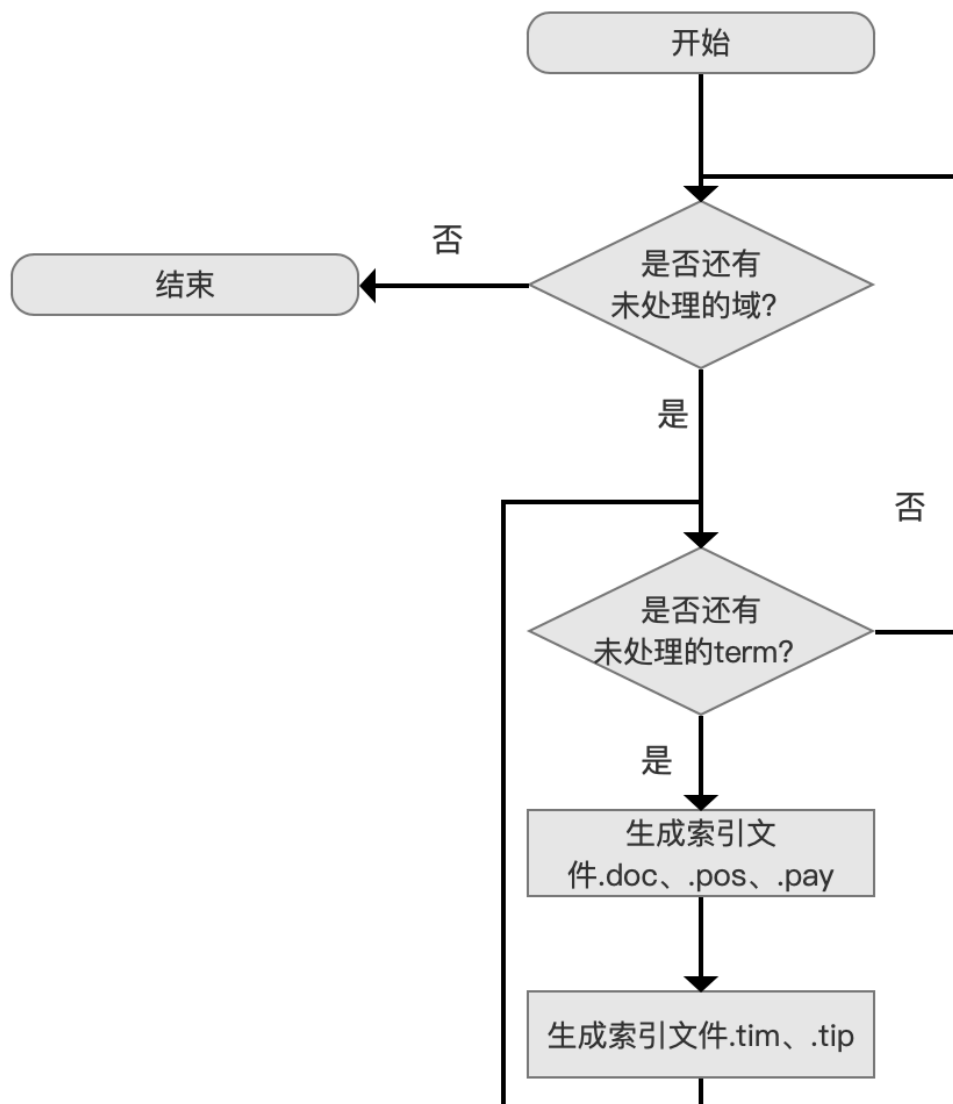
图一中的流程是flush()阶段的其中一个流程点，完整的flush()过程可以看系列文章[文档提交之flush](#)，索引文件的生成系列文章将会介绍图一中红框标注的每一个流程点，本篇文章先介绍生成索引文件 .tim、.tip、.doc、.pos、.pay 流程点。

## 生成索引文件.tim、.tip、.doc、.pos、.pay

在添加文档阶段，一篇文档中的term所属文档号docId，在文档内的出现次数frequency，位置信息position、payload信息、偏移信息offset，会先被存放到[倒排表](#)中，随后在flush()阶段，读取倒排表的信息，将这些信息写入到索引文件.tim、.tip、.doc、.pos、.pay中。

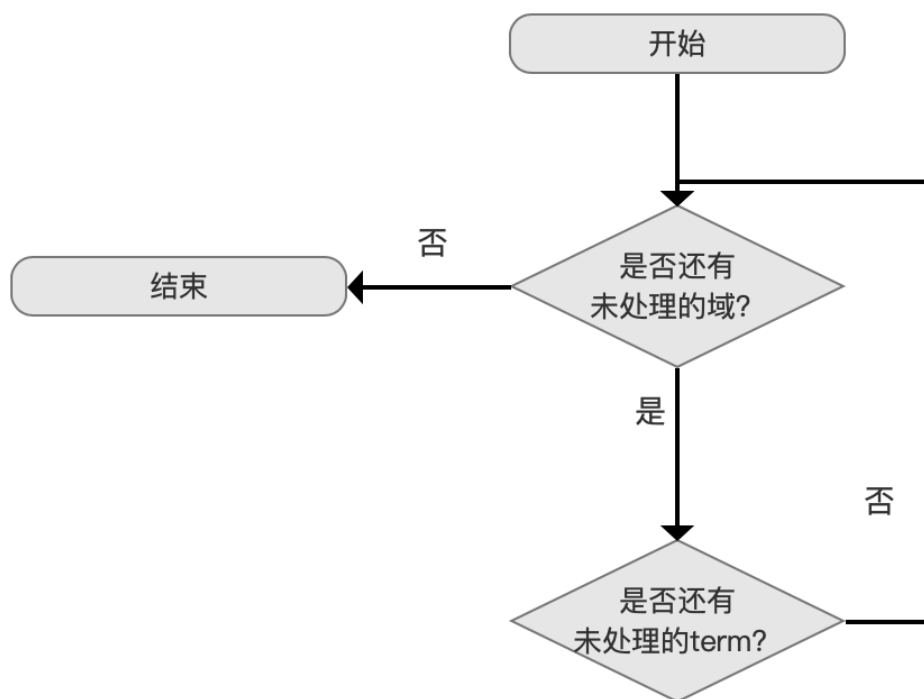
## 生成索引文件.tim、.tip、.doc、.pos、.pay的流程图

图2：



## 写入索引文件的顺序


图3:



在文章[倒排表](#)中我们知道，倒排表中的内容按照域进行划分，域之间可能存在相同的term，但是一个域内term是唯一的，故其写入索引文件的顺序如图3所示，域间（between filed）根据域名（field name）的字典序处理，域内（inner field）按照term的字典序进行处理。

## 生成索引文件.doc、.pos、.pay

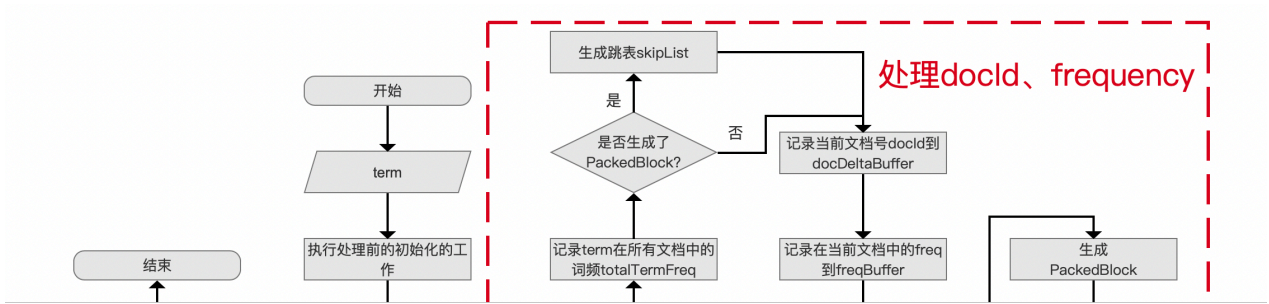
图4：



我们先介绍在一个域内，生成索引文件.doc、.pos、.pay的逻辑。

## 生成索引文件.doc、.pos、.pay的流程图

图5：

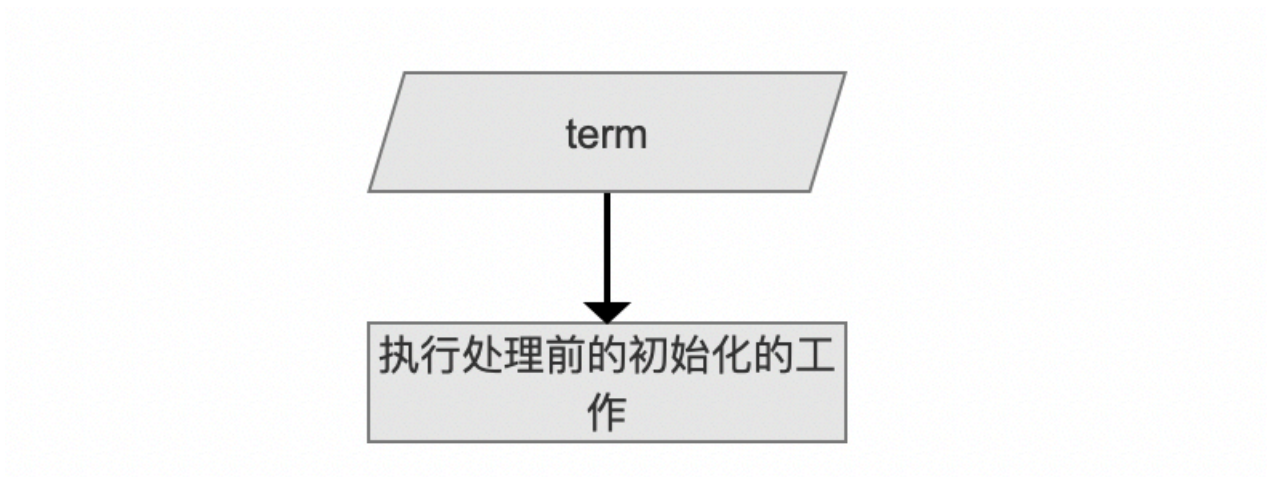


[点击查看大图](#)

图5描述的是同一个域内处理一个term，生成索引文件.doc、.pos、.pay的过程。

执行处理前的初始化的工作

图6：



依次处理当前域中所有的term，并且是按照term的字典序处理。

为什么要按照term的字典序处理：

- 在后面介绍生成[索引文件.tim、.tip](#)时，需要存储term的值，而相邻有序的term更有可能具有相同的前缀值，那么通过前缀存储（见[索引文件之tim&&tip](#)）就可以节省存储空间。

在处理一个term前，我们先要 **执行处理前的初始化的工作**，工作内容为获取上一个term后处理结束后的信息，包括以下信息：

- docStartFP: 当前term在索引文件.doc中的起始位置, 在后面的流程中, 当前term的文档号 docId、词频frequency信息将从这个位置写入, 因为索引文件是以数据流的方式存储, 所以 docStartFP也是上一个term对应的信息在索引文件.doc中的最后位置+1
- posStartFP: 当前term在索引文件.pos中的起始位置, 在后面的流程中, 当前term的位置 position信息从这个位置写入, 因为索引文件是以数据流的方式存储, 所以posStartFP也是上一个term对应的信息在索引文件.pos中的最后位置+1
- payStartFP: 当前term在索引文件.pay中的起始位置, 在后面的流程中, 当前term的偏移offset、payload信息从这个位置写入, 因为索引文件是以数据流的方式存储, 所以payStartFP也是上一个term对应的信息在索引文件.pay中的最后位置+1
- 重置跳表信息: 该信息在后面介绍跳表时再展开介绍

图7:

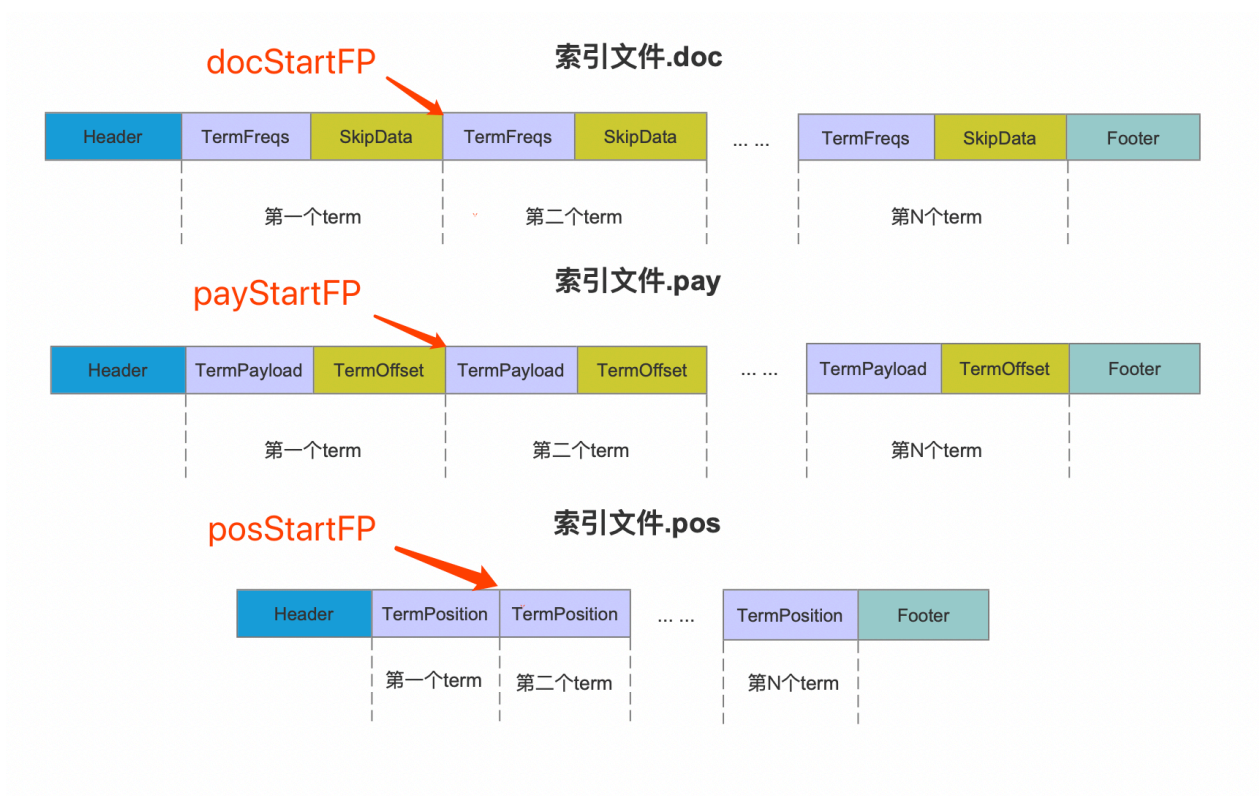



图7中, 如果当前开始处理**第二个term**, 那么此时docStartFP (docStart File Pointer缩写)、posStartFP、payStartFP如上所示。

是否还有文档包含当前term?

图8:



按照文档号从小到大，依次处理当前term在一篇文档中的信息，这些文档中都包含当前term。

记录当前文档号到docSeen

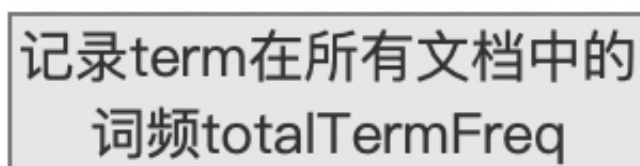
图9:



使用[FixedBitSet](#)对象docSeen来记录当前的文档号，docSeen在生成[索引文件.tim、.tip](#)时会用到，这里我们只要知道它生成的时间点就行。

记录term所有文档中的词频totalTermFreq

图10:



这里说的所有文档指的是包含当前term的文档，一篇文档中可能包含多个当前term，那么每处理一篇包含当前term的文档，term在这篇文档中出现的次数增量到totalTermFreq，totalTermFreq中存储了term在所有文档中出现的次数

该值将会被存储到[索引文件.tim、.tip](#)中，在搜索阶段，totalTermFreq该值用来参与打分计算（见系列文章[查询原理](#)）。

是否生成了PackedBlock?

图11:



每当处理128篇包含当前term的文档，就需要将term在这些文档中的信息，即文档号docId跟词频frequency，使用[PackedInts](#)进行压缩存储，生成一个PackedBlock。

图12：

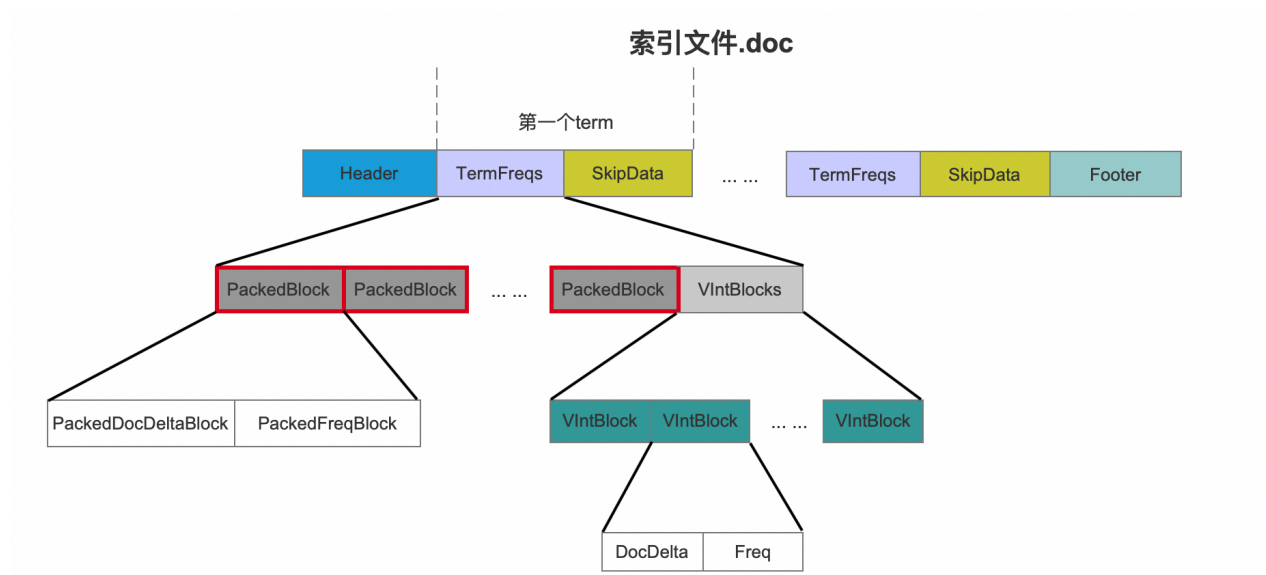


图12中，红框标注的即PackedBlock，关于PackedBlock的介绍以及几个问题在后面的流程中会介绍，这里先抛出这几个问题：

- 为什么要生成PackedBlock
- 为什么选择128作为生成PackedBlock的阈值

### 生成跳表skipList

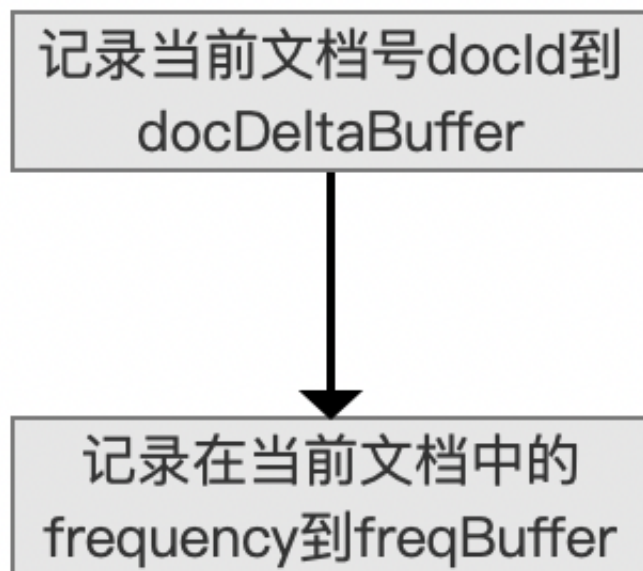
图13：



如果生成了一个PackedBlock，那么需要生成跳表，使得能在读取阶段能快速跳转到指定的PackedBlock，跳表skipList的介绍将在后面的文章中详细介绍，这里只要知道生成的时机点即可。

记录文档号跟词频信息

图14:



将文档号跟term在当前文档中的词频frequency分别记录到两个数组docDeltaBuffer、freqBuffer中，注意的是由于文档号是按照从小到大的顺序处理的，所以docDeltaBuffer数组存放的是与上一个文档号的差值，但是term在每个文档中的词频frequency是无序的，所以无法使用差值存储词频frequency，故在freqBuffer数组中，数组元素是原始的词频值。

为什么使用差值存储：

能降低存储空间的使用量，如果我们有下面的待处理的文档号集合，数组中按照文档号从小到大有序：

```
1 | int[] docIds = {1, 3, 7, 10, 12, 13, 17}
```

如果我们使用固定字节存储（见[PackedInts \(一\)](#)），那么根据17（数组中的最大值）的二进制为00010001，最少可以使用5个bit位（有效数据位）才能描述17，那么数组的其他元素都是用5个bit位存储的话，一共7个数组元素，共需要 $5 \times 7 = 35$ 个bit，如果使用差值存储（当前数组元素与前一个数组元素的差值），在计算了差值后，数组docIds如下所示：

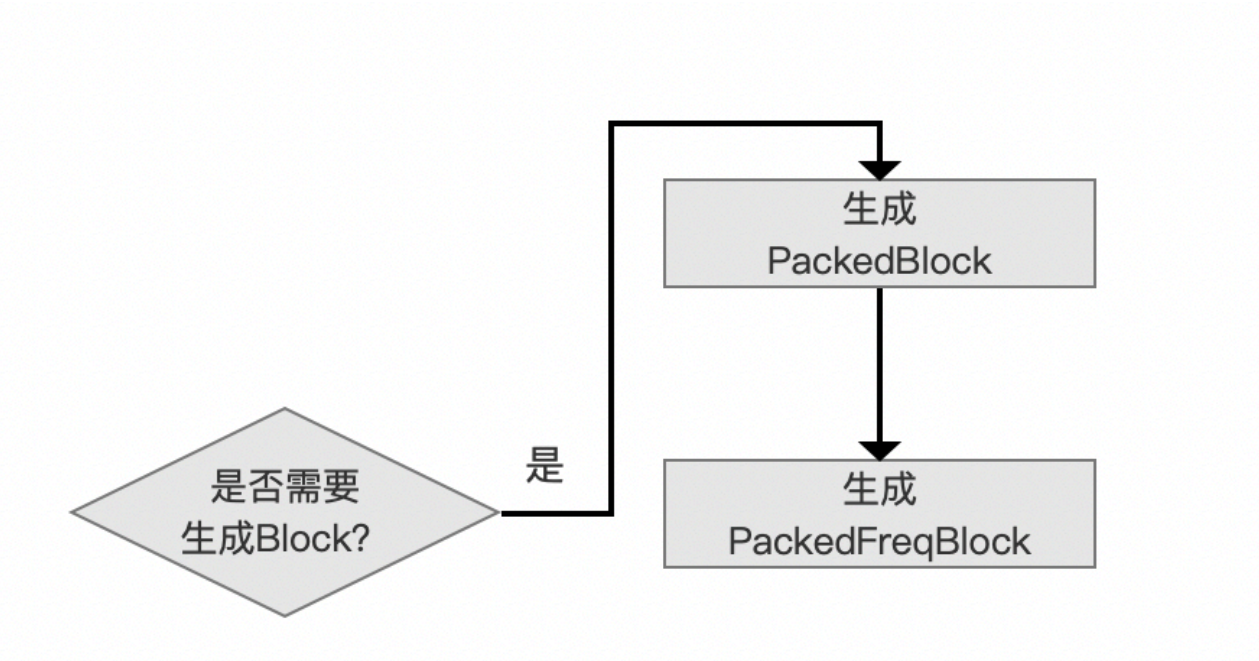
```
1 | int[] docIds = {1, 2, 4, 3, 2, 1, 4}
```

docIds数组中最大值为4，二进制位00000100，那么所有数组元素使用3个bit位存储，共需要 $3 \times 7 = 21$ 个bit，可见能有效的降低存储空间。

生成Block

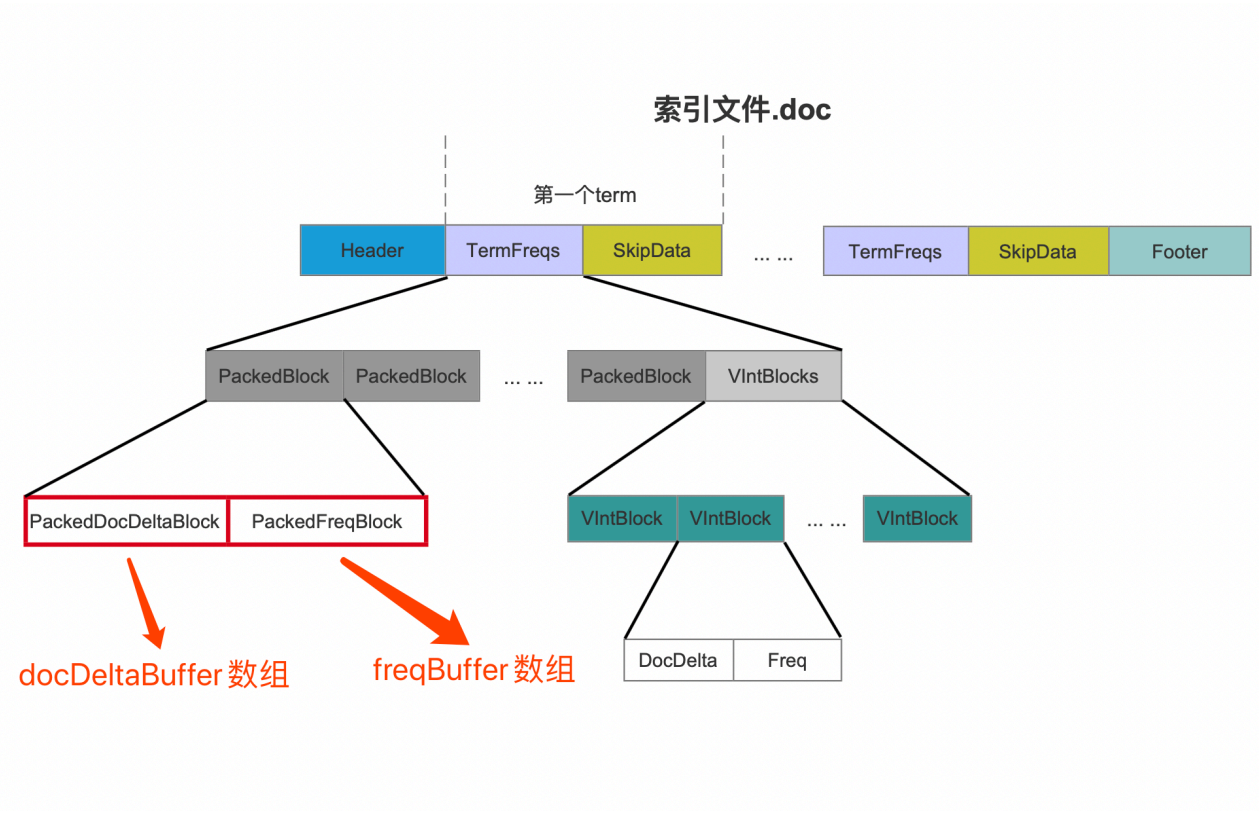


图15:



当数组docDeltaBuffer中的数组元素个数达到128个以后，意味着已经处理了128篇文档，此时需要生成Block，即将数组docDeltaBuffer、freqBuffer中的数据经过[PackerInts](#)处理后生成一个PackedBlock，如下所示：

图16:



## 结语

基于篇幅，剩余的流程将在下一篇文档中展开。

[点击](#)下载附件