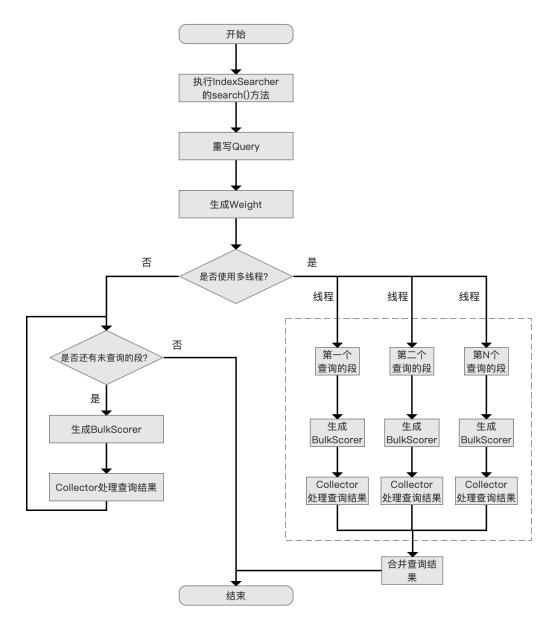
查询原理 (五) 终

本文承接查询原理(四),继续介绍查询原理。

查询原理流程图

图1:



点击查看大图

合并查询结果

该流程点遍历所有子收集器的结果,对这些进行结果进行合并,合并过程比较简单,即利用优先级 队列,由于太过简单,故不详细展开了。

遗留问题

在介绍这个遗留问题前,我们先说下在<u>查询原理(三)</u>的文章中,我们在介绍ReqExclBulkScorer 时,有两个信息没有介绍,即cost、next,这两个信息用来选择哪些子查询进行处理。

图2:

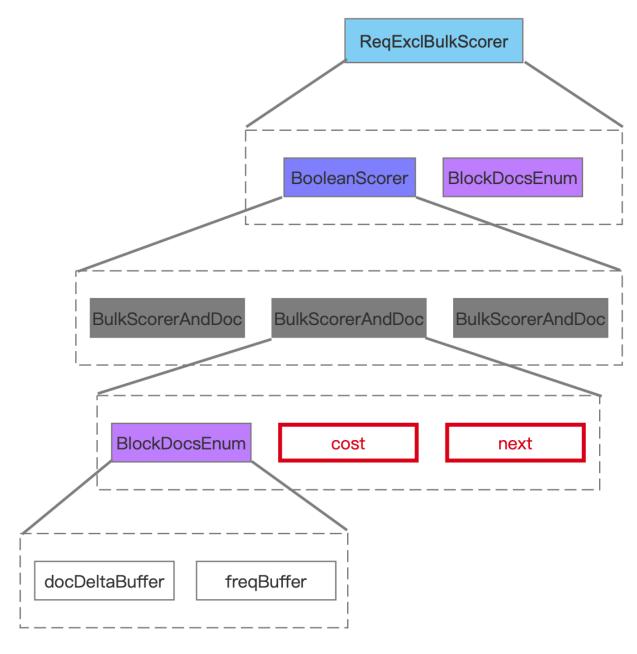


图3:

子杏	泊	1
	ريس	

docDeltaBuffer	0	2	3	4	5	8			
数组下标	0	1	2	3	4	5	6		
		ı	ı	1	I	ı	I	1	
freqBuffer	2	1	2	1	1	1			
数组下标	0	1	2	3	4	5	6		
docDeltaBuffer	1	4	7	8					
数组下标	0	1	2	3	4	5	6		
		I	I	I		I	I		
freqBuffer	2	1	3	1					
数组下标	0	1	2	3	4	5	6		
de a Dalka Dalffan									
docDeltaBuffer	0	2	3	4	6	8	9		
数组下标	0	1	2	3	4	5	6		
freqBuffer	1	1	1	1	1	3	2]	
数组下标	0	1	2	3	4	5	6		
AYSE 1.10/		' 	<u></u>		т 				
子查询4									
docDeltaBuffer	3	8							
数组下标	0	1	2	3	4	5	6		

● cost:该值描述的是满足子查询的文档个数,例如图3中的子查询3,因为docDeltaBuffer数组有7

个数组元素(数组元素为满足子查询的文档号),故它的cost值为7

● next:该值描述的是下一次处理的文档号,每当处理一篇文档,即更新到**Bucket数组**(见<u>查询原理(四)</u>),那么next被更新为下一个要处理的文档号,next的值是 一个递增值

在<u>查询原理(四)</u>的文章中,我们介绍了单线程下的查询原理的所有流程点,但还有一个很重要的逻辑没有介绍,那就是我们并没有介绍在还有未处理的子查询的情况下,如何选择哪个子查询进行处理,这个逻辑实际是个优化的过程,可能可以减少**遍历区间**(见<u>查询原理(四)</u>)的处理,下面将填补这个坑。

上文的描述可以拆分两个问题,以图3为例:

- 问题一:我们从子查询1、子查询2、子查询3中的哪个docDeltaBuffer开始遍历(选择子查询)
- 问题二:是不是所有的docDeltaBuffer的每一篇文档号都要遍历(减少遍历区间)?

这两个问题可以转化为一道面试算法题,来了解面试者对Lucene的熟悉程度:有N个int类型数组,其中所有数组的数组元素都是有序的,同一个数组内的数组元素都是不重复的,设计一种方法,从这N个数组中找出所有重复(minShouldMatch 大于等于2)的数组元素。

对于上述的算法题,以图3为例,对于子查询1、子查询2、子查询3,总的时间复杂度至少为3个子查询的开销的和(子查询的开销即上文中的cost),即我们需要遍历每一个子查询对应的文档号。

Lucene是如何处理的:

● 下图给出Lucene中处理方式的注释,原注释可以看这里: https://github.com/LuXugang/Lucene-7.5.0/blob/master/solr-7.5.0/lucene/core/src/java/org/apache/lucene/search/MinShouldMatchSumScorer.java中cost()方法的注释

图4:

```
static long cost(LongStream costs, int numScorers, int minShouldMatch) {
    // the idea here is the following: a boolean query c1,c2,...cn with minShouldMatch=m
    // could be rewritten to:
    // (c1 AND (c2..cn|msm=m-1)) OR (!c1 AND (c2..cn|msm=m))
    // if we assume that clauses come in ascending cost, then
    // the cost of the first part is the cost of c1 (because the cost of a conjunction is
    // the cost of the least costly clause)
    // the cost of the second part is the cost of finding m matches among the c2...cn
    // remaining clauses
    // since it is a disjunction overall, the total cost is the sum of the costs of these
    // two parts

// If we recurse infinitely, we find out that the cost of a msm query is the sum of the
    // costs of the num_scorers - minShouldMatch + 1 least costly scorers
```

- 图4中描述了这么一个结论:如果BooleanQuery有n个子查询,它们之间为BooleanClause.Occur.SHOULD的关系,并且minShouldMatch为m,那么BooleanQuery的开销最少可以是(numScores minShouldMatch + 1)个子查询的开销和,也就说在某些情况下我们不用遍历所有子查询对应的文档集合
 - numScores: 子查询的个数n
 - o minShouldMatch: 文档必须同时满足BooleanQuery中的至少m个子查询的查询条件

BooleanQuery的开销最少可以是(numScores - minShouldMatch + 1)个子查询的开销和是怎么推算出来的:

● 包含n个子查询c1, c2, ... cn且minShouldMatch为m的BooleanQuery, 它可以转化为

(c1 AND (c2..cn | msm = m - 1)) OR (!c1 AND (c2..cn | msm = m)), 两块部分通过"或的关系" (OR) 组合而成:

- (c1 AND (c2..cn|msm=m-1)): 第一块部分描述了满足BooleanQuery查询要求的文档,如果**满足** 子查询c1,那么必须至少满足c2..cn中任意m-1个子查询
- (!c1 AND (c2..cn|msm=m)): 第二块部分描述了满足BooleanQuery查询要求的文档,如果**不满足** 子查询c1,那么必须至少满足c2..cn中任意m个子查询
 - 根据两块部分的组合关系,BooleanQuery的开销是这两部分的开销和
- 假设子查询c1, c2, ... cn是按照cost(上文中已经介绍)**升序排序**的,那么对于第一块部分(c1 AND (c2..cn|msm=m-1)),由于c1的cost最小,并且必须满足c1的查询条件,**所以第一块部分的 开销就是c1的开销**
- 对于第二块部分(!c1 AND (c2..cn|msm=m)),它相当于一个包含 n -1 个子查询c2,... cn且 minShouldMatch为m的**子BooleanQuery**,所以它又可以转化为(c2 AND (c3..cn|msm=m-1)) OR (!c2 AND (c3..cn|msm=m))
- 以此类推如下所示

图5:

$$(c_1 \ AND \ (c_2 \dots c_n \mid msm = m-1)) \ OR \ (!c_1 \ AND \ (c_2 \dots c_n \mid msm = m))$$
 $c_1 \ OR \ (c_2 \ AND \ (c_3 \dots c_n \mid msm = m-1)) \ OR \ (!c_2 \ AND \ (c_3 \dots c_n \mid msm = m))$
 $c_1 \ OR \ c_2 \ OR \ (c_3 \ AND \ (c_4 \dots c_n \mid msm = m-1)) \ OR \ (!c_3 \ AND \ (c_4 \dots c_n \mid msm = m))$
 $c_1 \ OR \ c_2 \ OR \ c_3 \ OR \dots OR \ c_{n-m-1} \ OR \ (c_{n-m} \ AND \ (c_{n-m} \dots c_n \mid msm = m-1)) \ OR \ (!c_{n-m} \ AND \ (c_{n-m+1} \dots c_n \mid msm = m))$

点击查看大图

在图5中,最后推导出BooleanQuery的总开销为 n-m+1个查询的开销,所以在Lucene中,它使用优先级队列head(大小为n-m+1)、tail(大小为m - 1)来存放子查询的信息(即<u>查询原理(三)</u>中的BulkScorerAndDoc),优先级队列的排序规则如下:

head:按照cost升序tail:按照next升序

当head中优先级最低的BulkScorerAndDoc的文档号不在遍历区间内,那么就可以跳过这个遍历区间,即使此时tail中还有其他的BulkScorerAndDoc。

这里提供一个demo: https://github.com/LuXugang/Lucene-7.5.0/blob/master/LuceneDemo/s rc/main/java/lucene/query/BooleanQuerySHOULDNOTTEST.java,这个demo对应图3的内容,根据子查询4,我们会获得3个遍历区间(见查询原理(四)),即[0,3)、[4,8)、[9,2147483647),但是实际只需要遍历[0,3)、[4,8),因为子查询1、子查询2会被放到head中,而这满足这两个查询的最

大文档号为8,故不用处理[9,2147483647)的遍历区间,所以能降低时间复杂度,并且m的值越大,查询开销越小。

结语

至此,BooleanQuery的其中一种组合模式介绍完毕,其他的组合方式在后面不会详细展开,只介绍文档合并的逻辑,比如<u>文档号合并(SHOULD)</u>、文档号合并(<u>MUST</u>)。

点击下载附件