PackedInts (二)

本文承接PackedInts (一),继续介绍剩余的内容。

压缩实现

在上一篇文章中,我们介绍了Lucene 7.5.0中PackedInts提供的几种压缩实现,如下所示:

表1:

数据分布	是否有填充bit	是否单block单值	实现类
一个block	否	是	Direct8 Direct16 Direct32 Direct64
	是	否	Packed64SingleBlock1 Packed64SingleBlock2 Packed64SingleBlock3 Packed64SingleBlock4 Packed64SingleBlock5 Packed64SingleBlock6 Packed64SingleBlock7 Packed64SingleBlock8 Packed64SingleBlock9 Packed64SingleBlock10 Packed64SingleBlock12 Packed64SingleBlock12 Packed64SingleBlock21 Packed64SingleBlock21 Packed64SingleBlock32
两个block	否	否	Packed64
三个block	否	-	Packed8ThreeBlocks Packed16ThreeBlocks

我们接着介绍如何选择这些压缩实现:

在源码中Lucene会根据使用者提供的三个参数来选择其中一种压缩实现,即PackedInts类中的 getMutable(int valueCount, int bitsPerValue, float acceptableOverheadRatio)方法,参数如下所示:

• valueCount: 描述待处理的数据集的数量

• bitsPerValue: 描述待处理的数据集中的最大值, 它的有效数据占用的bit个数

• acceptableOverheadRatio: 描述可接受的开销

什么是可接受的开销acceptableOverheadRatio:

bitsPerValue描述了每一个数值占用的bit位个数, acceptableOverheadRatio则是每一个数值额外的空间开销的比例,允许使用比bitsPerValue更多的bit位,我们称之为maxBitsPerValue,来存储每一个数值,计算公式如下所示:

```
int maxBitsPerValue = bitsPerValue + (int)(bitsPerValue *
acceptableOverheadRatio)
```

例如我们有以下的数据集:

数组一:

```
1 | long[] values = {3, 8, 7, 12, 18};
```

该数组的bitsPerValue为5,如果此时acceptableOverheadRatio的值为7,那么maxBitsPerValue = 5 + 5*7 = 40,即允许使用40个bit位来存储数组一。

当然Lucene并不会真正的使用40个bit来存储一个数值,**maxBitsPerValue只是用来描述使用者可接受的额外开销的程度**。

为什么要使用acceptableOverheadRatio:

使得在使用者可接受的额外开销前提下,尽量使用读写性能最好的压缩来处理,我们先看下源码中 的部分代码截图:

图1:

```
if (bitsPerValue <= 8 && maxBitsPerValue >= 8) {
   actualBitsPerValue = 8;
  } else if (bitsPerValue <= 16 && maxBitsPerValue >= 16) {
   actualBitsPerValue = 16;
} else if (bitsPerValue <= 32 && maxBitsPerValue >= 32) {
   actualBitsPerValue = 32;
} else if (bitsPerValue <= 64 && maxBitsPerValue >= 64) {
   actualBitsPerValue = 64:
} else if (<u>valueCount</u> <= Packed8ThreeBlocks.MAX_SIZE && bitsPerValue <= 24 && maxBitsPerValue >= 24) {
   <u>actualBitsPerValue</u> = 24;
} else if (valueCount <= Packed16ThreeBlocks.MAX_SIZE && bitsPerValue <= 48 && maxBitsPerValue >= 48) {
   actualBitsPerValue = 48;
    for (int bpv = bitsPerValue; bpv <= maxBitsPerValue; ++bpv) {</pre>
      if (Format.PACKED_SINGLE_BLOCK.isSupported(bpv)) {
        float overhead = Format.PACKED_SINGLE_BLOCK.overheadPerValue(bpv);
        float acceptableOverhead = acceptableOverheadPerValue + bitsPerValue - bpv;
        if (overhead <= acceptableOverhead) {</pre>
          actualBitsPerValue = bpv;
          <u>format</u> = Format.PACKED_SINGLE_BLOCK;
    if (actualBitsPerValue < 0) {</pre>
      actualBitsPerValue = bitsPerValue;
```

先说明下上图的一些内容,actualBitsPerValues的值在后面的逻辑中用来选择对应的压缩实现,actualBitsPerValues与压缩实现的对应关系如下:

• 8: Direct8

16: Direct1632: Direct3264: Direct64

• 24: Packed8ThreeBlocks

• 48: Packed16ThreeBlocks

● 随后先考虑是否能用Packed64SingleBlock*(红框表示),最后才考虑使用Packed64

在第250行的if语句判断中,如果bitsPerValues的值小于等于8,并且maxBitsPerValue大于等于8,那么就使用Direct8来处理,在文章<u>PackedInts(一)</u>中我们知道,Direct*的压缩实现是读写性能最好的,可以看出来acceptableOverheadRatio是空间换时间的设计思想,并且压缩实现的选择优先级如下所示:

Direct* > Packed*ThreeBlocks > Packed64SingleBlock* > Packed64

acceptableOverheadRatio的取值范围是什么:

Lucene提供了以下几种取值:

表2:

acceptableOverheadRatio	源码中的描述	
7	At most 700% memory overhead, always select a direct implementation.	
0.5	At most 50% memory overhead, always select a reasonably fast implementation	
0.25	At most 25% memory overhead	
0	No memory overhead at all, but the returned implementation may be slow.	

acceptableOverheadRatio的值为7

如果acceptableOverheadRatio的值为7,那么不管bitsPerValue是区间[1, 64]中的哪一个值,总是会选择Direct*压缩实现。例如bitsPerValue的值为1,那么maxBitsPerValue = 1 + 1*7 = 8,那么根据图1中第250行的判断,就会使用Direct8来处理,意味着每一个数值使用8个bit位存储,由于每一个数值的有效数据的bit位个数为1,那么每个数值的额外开销为7个bit,即表2中描述的At most 700%memory overhead。

acceptableOverheadRatio的值为0.5

如果acceptableOverheadRatio的值为0.5,那么总能保证选择除了Packed64的其他任意一个压缩 实现,它们是比较快(reasonably fast)的实现。

acceptableOverheadRatio的值为0.25

相对acceptableOverheadRatio的值为0的情况获得更多的非Packed64的压缩实现。

acceptableOverheadRatio的值为0

没有任何额外的空间开销,虽然读写性能慢,但是因为使用了固定位数按位存储,并且没有填充bit(见<u>PackedInts(一)</u>),所以有较高的压缩率。

Packed64的实现

表4中的所有压缩实现,除了Packed64,其他的实现逻辑由于过于简单就不通过文章介绍了,而Packed64的实现核心是BulkOperation,BulkOperation中根据bitsPerValue从1到64的不同取值一共有64种不同的逻辑,但他们的实现原理是类似的,故感兴趣的同学可以看文章<u>BulkOperationPacked</u>来了解其中的一个实现。

结语

无

点击下载附件