doc文件

索引文件.doc中按块（block）的方式存放了每一个term的文档号、词频，并且保存skip data来实现块之间的快速跳转，本篇只介绍.doc文件的数据结构，其生成过程见文章索引文件的生成（一）。

doc文件的数据结构

图1：

TermFreqs保存了term的所有文档号、词频信息，TermFreqs中按块存储，使用SkipData实现这些块之间的快速跳转。

TermFreqs

图2：

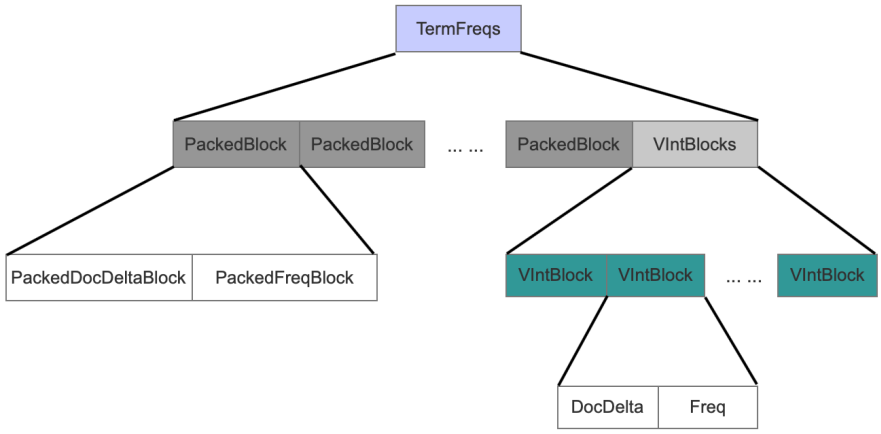

PackedBlock

```
1 每处理包含term的128篇文档，就将这些文档的信息处理为一个PackedBlock。
```

PackedDocDeltaBlock

```
1 PackedDocDeltaBlock存放了128篇文档的文档号，计算相邻两个文档号的差值后，利用
  PackedInts压缩存储。
```

PackedFreqBlock

```
PackedFreqBlock存放了term分别在128文档中的词频，利用PackedInts压缩存储。
```

这里注意是由于在每篇文档中的词频值无法保证递增，使用PackedInts只能压缩原始的词频值。

VIntBlocks && VIntBlock

```
如果包含term的文档号不足128个，那么将这些文档的信息处理为一个VIntBlocks。(比如包含term的文档数量有200，那么前128篇文档的信息被处理为一个PackedBlock，剩余的72篇文档处理为72个VIntBlock，72个VIntBlock为一个VIntBlocks)
```

DocDelta

```
当前文档号跟上一个文档号的差值。
```

Freq

```
term在当前文档中的词频。
```

在介绍SkipData前先介绍下跳表（SkipList）的概念，注意的是下图只是跳表的概述，并不是Lucene中的实现，在后面的文章中，会介绍跳表的生成与读取：

图3：

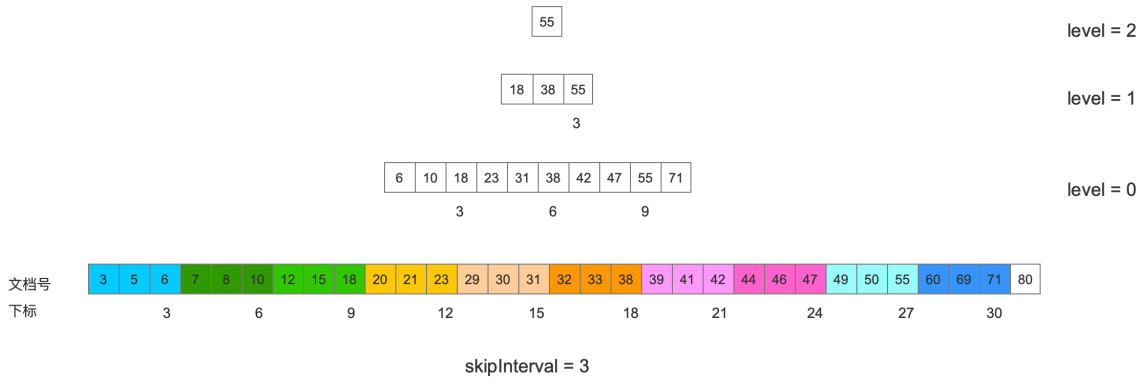

在每一层中，每3个数据块就会在上一层中添加一个索引，实现了对数级别的时间复杂度。

比如我们要找文档号为33的值。那么查找的过程如下图。

图4：

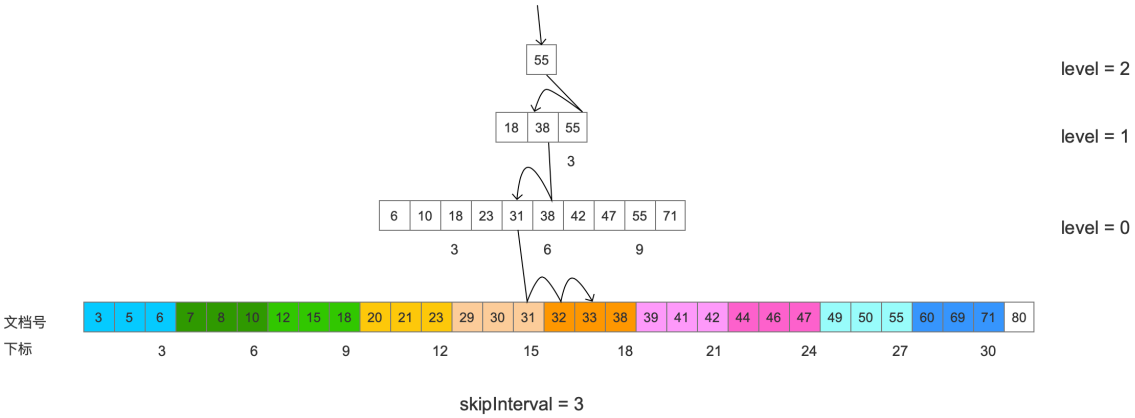

SkipData

图5：

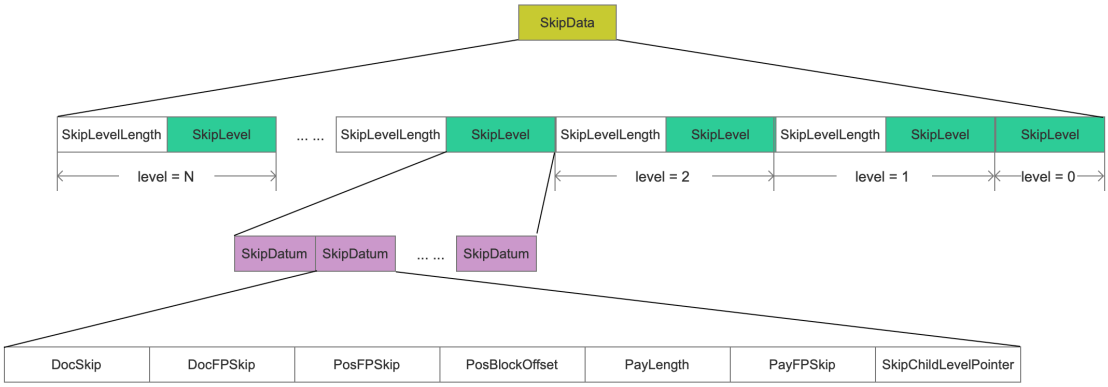

SkipLevelLength

```
1 当前层的跳表（skipList）数据长度，在读取的时候用来确定往后读取的一段数据区间。
```

SkipLevel

```
1 SkipLevel描述了当前层中的所有跳表真实数据
```

SkipDatum

```
1 当前层中每一个跳表信息按块处理为一个SkipDatum。
```

DocSkip

```
1 描述了当前SkipDatum指向的文档号，不过DocSkip的实际值是当前文档号与上一个SkipDatum的文档号差值，还是使用了差值存储。
```

DocFPSkip

```
每当处理128篇文档，在level = 0的跳表中就会生成一个SkipDatum，而DocFPSkip指向的就是存储这128篇文档的PackedBlock的起始位置。
```

PosFPSkip

```
PosFPSkip指向了.pos文件中一个位置。这个位置是PackedPosBlock(每128个position信息处理为一个PackedPosBlock)的起始位置
```

PosBlockOffset

```
PosBlockOffset描述的是上一条说的PackedPosBlock中的一个偏移位置。
```

PayLength

```
PayLength描述的是在.pay文件中的payload的信息，这段payload的信息跟上一条中位置信息是对应的。
```

PayFPSkip

```
PayFPSkip指向了.pay文件中一个位置。这个位置是PackedPayBlock(每128个offset信息处理为一个PackedPayBlock)的起始位置。
```

SkipChildLevelPointer

```
如果当前SkipDatum属于大于level = 0的较高层，那么SkipChildLevelPointer指向了下一层的某个位置。
```

多个域的doc文件的数据结构

图6：

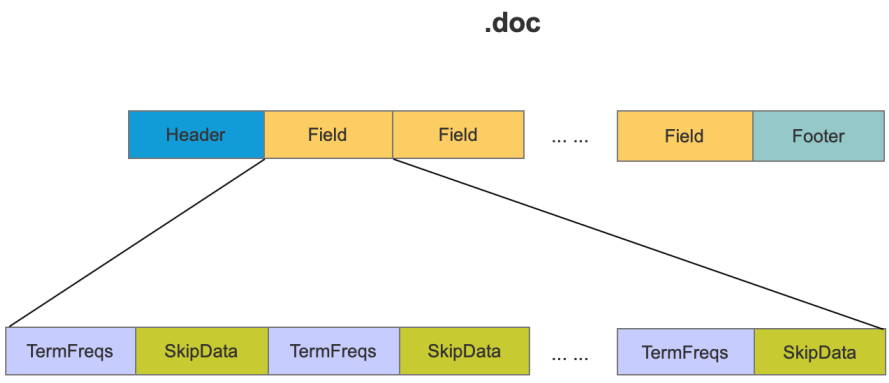

结语

.pos、.pay、.doc、.tim、.tip文件都是通过读取内存倒排表的过程中一起生成的，在处理完每个term的信息并写入.pos、.pay、.doc文件后，开始生成.tim、.tip文件，在最后的文章中会更新这部分内容。

点击下载Markdown文件