## doc文件

索引文件doc中按块(block)的方式存放了每一个term的文档号、词频,并且保存了skip data来实现块之间的快速跳转。

## doc文件的数据结构

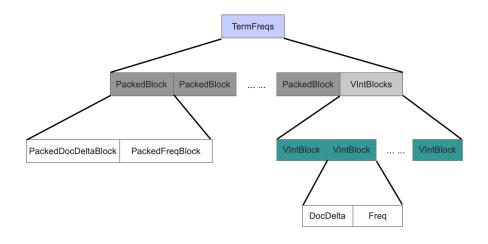
图1:



TermFreqs保存了term的所有文档号、词频信息,TermFreqs中按块存储,所以SkipData实现这些块之间的快速跳转。

# **TermFreqs**

### 图2:



### **PackedBlock**

每处理包含term的128篇文档,就将这些文档的信息处理为一个PackedBlock。

### **PackedDocDeltaBlock**

PackedDocDeltaBlock存放了128篇文档的文档号,计算相邻两个文档号的差值后,利用PackedInts压缩存储。

### **PackedFreqBlock**

PackedFregBlock存放了term分别在128文档中的词频,利用PackedInts压缩存储。

这里注意是由于在每篇文档中的词频值无法保证递增,而在使用PackedInts时会用统一大小的字节数来存放每一个词频值,并且这个字节数取决于词频最大的那个。

### VIntBlocks && VIntBlock

如果包含term的文档号不足128个,那么将这些文档的信息处理为一个VIntBlocks。(比如包含term的文档数量有200,那么前128篇文档的信息被处理为一个PackedBlock,剩余的72篇文档处理为72个VIntBlock,72个VIntBlock为一个VIntBlocks)

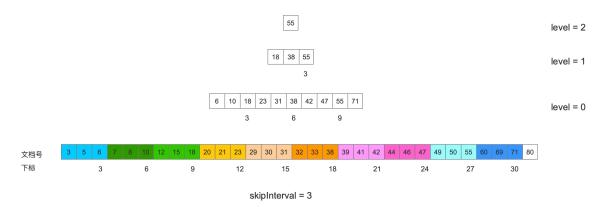
#### **DocDelta**

当前文档号跟上一个文档号的差值。

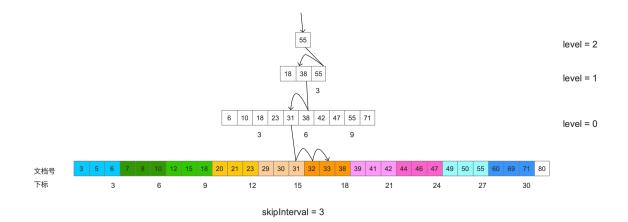
#### Freq

term在当前文档中的词频。

在介绍SkipData前先介绍下跳表(SkipList)的概念图3:

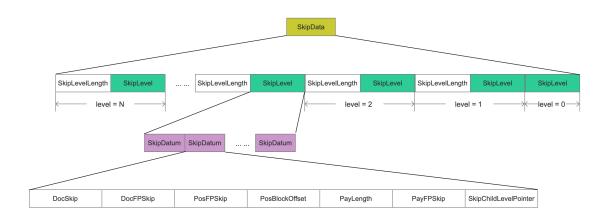


在每一层中,每skipInterval个数据块就会在上一层中添加一个索引,实现了对数级别的时间复杂度。 比如我们要找文档号为33的值。那么查找的过程如下图。 图4:



## **SkipData**

图5:



### SkipLevelLength

当前层的跳表(skipList)数据长度,在读取的时候用来确定往后读取的一段数据区间。

### **SkipLevel**

SkipLevel描述了当前层中的所有跳表真实数据

### SkipDatum

当前层中每一个跳表信息按块处理为一个SkipDatum。

### **DocSkip**

描述了当前SkipDatum指向的文档号,不过DocSkip的实际值是当前文档号与上一个SkipDatum的文档号差值,还是使用了差值存储。

### **DocFPSkip**

每当处理128篇文档,在level = 0的跳表中就会生成一个SkipDatum,而DocFPSkip指向的就是存储这128篇文档的PackedBlock的起始位置。

### **PosFPSkip**

PosFPSkip指向了.pos文件中一个位置。这个位置是PackedPosBlock(每128个position信息处理为一个PackedPosBlock)的起始位置

#### **PosBlockOffset**

PosBlockOffset描述的是上一条说的PackedPosBlock中的一个偏移位置。

### **PayLength**

PayLength描述的是在.pay文件中的payload的信息,这段payload的信息跟上一条中位置信息是对应的。

### **PayFPSkip**

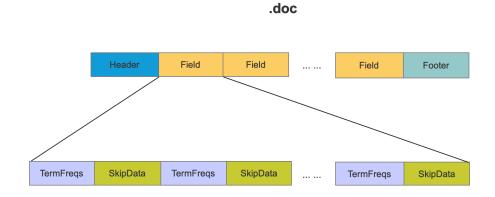
PayFPSkip指向了.pay文件中一个位置。这个位置是PackedPayBlock(每128个offset信息处理为一个PackedPayBlock)的起始位置。

### SkipChildLevelPointer

如果当前SkipDatum属于大于level = 0的较高层,那么SkipChildLevelPointer指向了下一层的某个位置。

# 多个域的doc文件的数据结构

图6:



# 结语

.pos、.pay、.doc、.tim、.tip文件都是通过读取内存倒排表的过程中一起生成的,在处理完每个term的信息并写入.pos、.pay、.doc文件后,开始生成.tim、.tip文件,在最后的文章中会更新这部分内容。

点击下载Markdown文件